

Bayes-päätely

Työterveyslaitos

8.-9.2.2018

Ville Hyvönen



1. Johdanto & Bayesin kaava

1. Bayesin kaava
2. Bayes-päätelyn käsitteet
3. Esimerkki Bayes-päätelystä
4. Hyvin lyhyt Bayes-päätelyn historia
5. Motivaatio

- Oletetaan, että meillä on käytössä testi jonkin harvinaisen sairauden toteamiseksi, ja määritellään seuraavat satunnaismuuttujat:

$$B = \begin{cases} 1, & \text{jos henkilöllä on tämä harvinainen sairaus} \\ 0, & \text{jos henkilöllä ei ole tätä sairautta,} \end{cases}$$

$$A = \begin{cases} 1, & \text{jos henkilön testitulos on positiivinen} \\ 0, & \text{jos henkilön testitulos on negatiivinen.} \end{cases}$$

- ▶ Testi on hyvin tarkka:

- ▶ Testi on hyvin tarkka:
 - ▶ testin sensitiivisyys, eli todennäköisyys saada positiivinen testitulos henkilölle, jolla on tutkittava sairaus, on $p(A = 1|B = 1) = 0.95$.

- ▶ Testi on hyvin tarkka:
 - ▶ testin sensitiivisyys, eli todennäköisyys saada positiivinen testitulos henkilölle, jolla on tutkittava sairaus, on $p(A = 1|B = 1) = 0.95$.
 - ▶ testin spesifisyys, eli todennäköisyys saada negatiivinen testitulos henkilölle jolla ei ole tutkittavaa sairautta, on $p(A = 0|B = 0) = 0.99$.

- ▶ Testi on hyvin tarkka:
 - ▶ testin sensitiivisyys, eli todennäköisyys saada positiivinen testitulos henkilölle, jolla on tutkittava sairaus, on $p(A = 1|B = 1) = 0.95$.
 - ▶ testin spesifisyys, eli todennäköisyys saada negatiivinen testitulos henkilölle jolla ei ole tutkittavaa sairautta, on $p(A = 0|B = 0) = 0.99$.
- ▶ Tauti on harvinainen: se esiintyy väestöstä keskimäärin vain yhdellä kymmenestä tuhannesta.


- ▶ Testi on hyvin tarkka:
 - ▶ testin sensitiivisyys, eli todennäköisyys saada positiivinen testitulos henkilölle, jolla on tutkittava sairaus, on $p(A = 1|B = 1) = 0.95$.
 - ▶ testin spesifisyys, eli todennäköisyys saada negatiivinen testitulos henkilölle jolla ei ole tutkittavaa sairautta, on $p(A = 0|B = 0) = 0.99$.
- ▶ Tauti on harvinainen: se esiintyy väestöstä keskimäärin vain yhdellä kymmenestä tuhannesta.
 - ▶ Kyseessä on seulonta, eli koehenkilö on valittu satunnaisotannalla väestöstä: hänellä ei ole (välttämättä) mitään oireita.

- ▶ Testi on hyvin tarkka:
 - ▶ testin sensitiivisyys, eli todennäköisyys saada positiivinen testitulos henkilölle, jolla on tutkittava sairaus, on $p(A = 1|B = 1) = 0.95$.
 - ▶ testin spesifisyys, eli todennäköisyys saada negatiivinen testitulos henkilölle jolla ei ole tutkittavaa sairautta, on $p(A = 0|B = 0) = 0.99$.
- ▶ Tauti on harvinainen: se esiintyy väestöstä keskimäärin vain yhdellä kymmenestä tuhannesta.
 - ▶ Kyseessä on seulonta, eli koehenkilö on valittu satunnaisotannalla väestöstä: hänellä ei ole (välttämättä) mitään oireita.
 - ▶ Tällöin todennäköisyys, että koehenkilöllä on tutkittava sairaus on $P(B = 1) = 0.0001$.


- ▶ Mikä on todennäköisyys, että koehenkilöllä on tutkittava sairaus, jos hänen testituloksensa on positiivinen:

$$p(B = 1|A = 1) = ?$$


- Positiivinen testitulos voidaan saada kahdella eri tavalla:



- ▶ Positiivinen testitulos voidaan saada kahdella eri tavalla:
 - ▶ Oikea positiivinen: koehenkilön, jolla on tutkittava sairaus, testitulos on positiivinen




- ▶ Positiivinen testitulos voidaan saada kahdella eri tavalla:
 - ▶ Oikea positiivinen: koehenkilön, jolla on tutkittava sairaus, testitulos on positiivinen
 - ▶ Väärä hälytys: terveen koehenkilön testitulos on positiivinen.



- Siten positiivisen testituloksen todennäköisyys on

$$\begin{aligned}P(A = 1) &= P(B = 0)P(A = 1|B = 0) + P(B = 1)P(A = 1|B = 1) \\&= 0.9999 \cdot 0.01 + 0.0001 \cdot 0.95 \\&= 0.009999 + 0.000095 = 0.010094.\end{aligned}$$



- Nyt todennäköisyys, että koehenkilöllä on tutkittava sairaus jos hänen testituloksensa on positiivinen saadaan tarkastelemalla kuinka suurella osuudella kaikista positiivisen testituloksen saaneista on tämä sairaus:

$$\begin{aligned} p(B = 1|A = 1) &= \frac{p(A = 1, B = 1)}{p(A = 1)} \\ &= \frac{p(B = 1)p(A = 1|B = 1)}{p(A = 1)} \\ &= \frac{0.000095}{0.010094} = 0.0094 \approx 1\% \end{aligned}$$


Oikeasti sairaat
(true positives)



Testin tarkkuus =
(precision)

$$\frac{\text{Oikeasti sairaat}}{\text{Kaikki positiiviset}} \approx \frac{1}{100}$$

Kaikki positiiviset
(true positives + false positives)



- Johdimme juuri Bayesin kaavan! Yleisemmin diskreeteille satunnaismuuttujille:

$$\begin{aligned} p(B = b|A = a) &= \frac{p(B = b)p(A = a|B = b)}{p(A = a)} \\ &= \frac{p(B = b)p(A = a|B = b)}{\sum_{b' \in \mathcal{B}} p(B = b')p(A = a|B = b')} \end{aligned}$$

- Johdimme juuri Bayesin kaavan! Yleisemmin diskreeteille satunnaismuuttujille:

$$\begin{aligned} p(B = b|A = a) &= \frac{p(B = b)p(A = a|B = b)}{p(A = a)} \\ &= \frac{p(B = b)p(A = a|B = b)}{\sum_{b' \in \mathcal{B}} p(B = b')p(A = a|B = b')} \end{aligned}$$

- Satunnaismuuttujat eivät enää välttämättä ole binäärisiä, joten summataan kaikkien B :n mahdollisten arvojen yli.

- ▶ Johdimme juuri Bayesin kaavan! Yleisemmin diskreeteille satunnaismuuttujille:

$$\begin{aligned} p(B = b|A = a) &= \frac{p(B = b)p(A = a|B = b)}{p(A = a)} \\ &= \frac{p(B = b)p(A = a|B = b)}{\sum_{b' \in \mathcal{B}} p(B = b')p(A = a|B = b')} \end{aligned}$$

- ▶ Satunnaismuuttujat eivät enää välttämättä ole binäärisiä, joten summataan kaikkien B :n mahdollisten arvojen yli.
 - ▶ Merkitään B :n kaikkien mahdollisten arvojen joukkoa \mathcal{B} :llä.

- ▶ Havaitaan **aineisto** $\mathbf{y} = (y_1, \dots, y_n)$.

- ▶ Havaitaan **aineisto** $\mathbf{y} = (y_1, \dots, y_n)$.
 - ▶ Voidaan mallintaa satunnaismuuttujien $\mathbf{Y} = (Y_1, \dots, Y_n)$ realisaatioina.

- ▶ Havaitaan **aineisto** $\mathbf{y} = (y_1, \dots, y_n)$.
 - ▶ Voidaan mallintaa satunnaismuuttujien $\mathbf{Y} = (Y_1, \dots, Y_n)$ realisaatioina.
 - ▶ Jatkossa merkitään kuitenkin sekä havaittua aineistoa että satunnaismuuttujia, joiden realisaatioina niitä mallinnetaan, samalla pienellä kirjaimella, ellei erikseen haluta korostaa niiden eroa.

- ▶ Havaitaan **aineisto** $\mathbf{y} = (y_1, \dots, y_n)$.
 - ▶ Voidaan mallintaa satunnaismuuttujien $\mathbf{Y} = (Y_1, \dots, Y_n)$ realisaatioina.
 - ▶ Jatkossa merkitään kuitenkin sekä havaittua aineistoa että satunnaismuuttujia, joiden realisaatioina niitä mallinnetaan, samalla pienellä kirjaimella, ellei erikseen haluta korostaa niiden eroa.
- ▶ Havainnot asuvat **otosavaruudessa** (sample space) \mathcal{Y} , voi olla esim.

- ▶ Havaitaan **aineisto** $\mathbf{y} = (y_1, \dots, y_n)$.
 - ▶ Voidaan mallintaa satunnaismuuttujien $\mathbf{Y} = (Y_1, \dots, Y_n)$ realisaatioina.
 - ▶ Jatkossa merkitään kuitenkin sekä havaittua aineistoa että satunnaismuuttujia, joiden realisaatioina niitä mallinnetaan, samalla pienellä kirjaimella, ellei erikseen haluta korostaa niiden eroa.
- ▶ Havainnot asuvat **otosavaruudessa** (sample space) \mathcal{Y} , voi olla esim.
 - ▶ Kaksialkoinen joukko: $\mathcal{Y} = \{0, 1\}$

- ▶ Havaitaan **aineisto** $\mathbf{y} = (y_1, \dots, y_n)$.
 - ▶ Voidaan mallintaa satunnaismuuttujien $\mathbf{Y} = (Y_1, \dots, Y_n)$ realisaatioina.
 - ▶ Jatkossa merkitään kuitenkin sekä havaittua aineistoa että satunnaismuuttujia, joiden realisaatioina niitä mallinnetaan, samalla pienellä kirjaimella, ellei erikseen haluta korostaa niiden eroa.
- ▶ Havainnot asuvat **otosavaruudessa** (sample space) \mathcal{Y} , voi olla esim.
 - ▶ Kaksialkoinen joukko: $\mathcal{Y} = \{0, 1\}$
 - ▶ Koko reaaliakseli: $\mathcal{Y} = \mathbb{R}$

- ▶ Havaitaan **aineisto** $\mathbf{y} = (y_1, \dots, y_n)$.
 - ▶ Voidaan mallintaa satunnaismuuttujien $\mathbf{Y} = (Y_1, \dots, Y_n)$ realisaatioina.
 - ▶ Jatkossa merkitään kuitenkin sekä havaittua aineistoa että satunnaismuuttujia, joiden realisaatioina niitä mallinnetaan, samalla pienellä kirjaimella, ellei erikseen haluta korostaa niiden eroa.
- ▶ Havainnot asuvat **otosavaruudessa** (sample space) \mathcal{Y} , voi olla esim.
 - ▶ Kaksialkoinen joukko: $\mathcal{Y} = \{0, 1\}$
 - ▶ Koko reaaliakseli: $\mathcal{Y} = \mathbb{R}$
 - ▶ Koko d -ulotteinen reaaliavaruus: $\mathcal{Y} = \mathbb{R}^d$ (Tällöin jokainen yksittäinen havainto on d -komponenttinen vektori: $\mathbf{y}_1 = (y_{i1}, \dots, y_{id})$ kaikille $i = 1, \dots, n$).

- ▶ Tavoitteena selvittää aineiston (ajateltun satunnaismuuttujana) **jakauma**.

- ▶ Tavoitteena selvittää aineiston (ajateltun satunnaismuuttujana) **jakauma**.
- ▶ Rajoitumme tässä **parametriseen tilastolliseen päättelyyn**, jossa aineiston jakauma oletetaan tunnetuksi tuntematonta parametrin arvoa vaille.

- ▶ Tavoitteena selvittää aineiston (ajateltun satunnaismuuttujana) **jakauma**.
- ▶ Rajoitumme tässä **parametriseen tilastolliseen päättelyyn**, jossa aineiston jakauma oletetaan tunnetuksi tuntematonta parametrin arvoa vaille.
- ▶ Merkitään aineiston **otantajakaumaa** (sampling distribution) (tai tarkemmin otantajakauman tiheys- tai pistetodennäköisyysfunktioita) $p(\mathbf{y}|\boldsymbol{\theta})$

- ▶ Tavoitteena selvittää aineiston (ajateltun satunnaismuuttujana) **jakauma**.
- ▶ Rajoitumme tässä **parametriseen tilastolliseen päättelyyn**, jossa aineiston jakauma oletetaan tunnetuksi tuntematonta parametrin arvoa vaille.
- ▶ Merkitään aineiston **otantajakaumaa** (sampling distribution) (tai tarkemmin otantajakauman tiheys- tai pistetodennäköisyysfunktioita) $p(\mathbf{y}|\theta)$
 - ▶ Esimerkiksi kruunien määrää y n :llä heitolla voidaan mallintaa binomijakaumalla:

$$p(y|\theta) = \binom{n}{y} \theta^y (1 - \theta)^{n-y}$$

- ▶ Tavoitteena selvittää aineiston (ajateltun satunnaismuuttujana) **jakauma**.
- ▶ Rajoitumme tässä **parametriseen tilastolliseen päättelyyn**, jossa aineiston jakauma oletetaan tunnetuksi tuntematonta parametrin arvoa vaille.
- ▶ Merkitään aineiston **otantajakaumaa** (sampling distribution) (tai tarkemmin otantajakauman tiheys- tai pistetodennäköisyysfunktioita) $p(\mathbf{y}|\theta)$
 - ▶ Esimerkiksi kruunien määrää y n :llä heitolla voidaan mallintaa binomijakaumalla:

$$p(y|\theta) = \binom{n}{y} \theta^y (1 - \theta)^{n-y}$$

- ▶ Tässä tuntematon parametri $\theta \in (0, 1)$ on kruunan todennäköisyys.

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.
 - ▶ Voi olla (ja lähes aina onkin) reaaliarvoinen: $\theta = (\theta_1, \dots, \theta_d)$

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.
 - ▶ Voi olla (ja lähes aina onkin) reaaliarvoinen: $\theta = (\theta_1, \dots, \theta_d)$
- ▶ Asuu **parametriavaruudessa** (parameter space) Ω , joka voi olla esim:

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.
 - ▶ Voi olla (ja lähes aina onkin) reaaliarvoinen: $\theta = (\theta_1, \dots, \theta_d)$
- ▶ Asuu **parametriavaruudessa** (parameter space) Ω , joka voi olla esim:
 - ▶ Avoin väli: $\Omega = (0, 1)$

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.
 - ▶ Voi olla (ja lähes aina onkin) reaaliarvoinen: $\theta = (\theta_1, \dots, \theta_d)$
- ▶ Asuu **parametriavaruudessa** (parameter space) Ω , joka voi olla esim:
 - ▶ Avoin väli: $\Omega = (0, 1)$
 - ▶ Koko reaaliakseli: $\Omega = \mathbb{R}$

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.
 - ▶ Voi olla (ja lähes aina onkin) reaaliarvoinen: $\theta = (\theta_1, \dots, \theta_d)$
- ▶ Asuu **parametriavaruudessa** (parameter space) Ω , joka voi olla esim:
 - ▶ Avoin väli: $\Omega = (0, 1)$
 - ▶ Koko reaaliakseli: $\Omega = \mathbb{R}$
 - ▶ Koko d -ulotteinen reaaliavaruus: $\Omega = \mathbb{R}^d$

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.
 - ▶ Voi olla (ja lähes aina onkin) reaaliarvoinen: $\theta = (\theta_1, \dots, \theta_d)$
- ▶ Asuu **parametriavaruudessa** (parameter space) Ω , joka voi olla esim:
 - ▶ Avoin väli: $\Omega = (0, 1)$
 - ▶ Koko reaaliakseli: $\Omega = \mathbb{R}$
 - ▶ Koko d -ulotteinen reaaliavaruus: $\Omega = \mathbb{R}^d$
 - ▶ Koko reaaliakselin ja positiivisen reaaliakselin karteesinen tulo: $\Omega = \mathbb{R} \times (0, \infty)$

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.
 - ▶ Voi olla (ja lähes aina onkin) reaaliarvoinen: $\theta = (\theta_1, \dots, \theta_d)$
- ▶ Asuu **parametriavaruudessa** (parameter space) Ω , joka voi olla esim:
 - ▶ Avoin väli: $\Omega = (0, 1)$
 - ▶ Koko reaaliakseli: $\Omega = \mathbb{R}$
 - ▶ Koko d -ulotteinen reaaliavaruus: $\Omega = \mathbb{R}^d$
 - ▶ Koko reaaliakselin ja positiivisen reaaliakselin karteesinen tulo: $\Omega = \mathbb{R} \times (0, \infty)$
- ▶ Parametri voi olla esimerkiksi:
 - ▶ Kruunan todennäköisyys $\theta \in (0, 1)$.

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.
 - ▶ Voi olla (ja lähes aina onkin) reaaliarvoinen: $\theta = (\theta_1, \dots, \theta_d)$
- ▶ Asuu **parametriavaruudessa** (parameter space) Ω , joka voi olla esim:
 - ▶ Avoin väli: $\Omega = (0, 1)$
 - ▶ Koko reaaliakseli: $\Omega = \mathbb{R}$
 - ▶ Koko d -ulotteinen reaaliavaruus: $\Omega = \mathbb{R}^d$
 - ▶ Koko reaaliakselin ja positiivisen reaaliakselin karteesinen tulo: $\Omega = \mathbb{R} \times (0, \infty)$
- ▶ Parametri voi olla esimerkiksi:
 - ▶ Kruunan todennäköisyys $\theta \in (0, 1)$.
 - ▶ Normaalijakauman odotusarvo ja varianssi $\theta = (\mu, \sigma^2) \in \mathbb{R} \times (0, \infty)$.

- ▶ Tavoitteena estimoida **parametrin** $\theta \in \Omega$ arvoja.
 - ▶ Voi olla (ja lähes aina onkin) reaaliarvoinen: $\theta = (\theta_1, \dots, \theta_d)$
- ▶ Asuu **parametriavaruudessa** (parameter space) Ω , joka voi olla esim:
 - ▶ Avoin väli: $\Omega = (0, 1)$
 - ▶ Koko reaaliakseli: $\Omega = \mathbb{R}$
 - ▶ Koko d -ulotteinen reaaliavaruus: $\Omega = \mathbb{R}^d$
 - ▶ Koko reaaliakselin ja positiivisen reaaliakselin karteesinen tulo: $\Omega = \mathbb{R} \times (0, \infty)$
- ▶ Parametri voi olla esimerkiksi:
 - ▶ Kruunan todennäköisyys $\theta \in (0, 1)$.
 - ▶ Normaalijakauman odotusarvo ja varianssi $\theta = (\mu, \sigma^2) \in \mathbb{R} \times (0, \infty)$.
 - ▶ Lineaarisen regression regressiokertoimet ja varianssi $\beta = (\beta_0, \beta_1, \dots, \beta_d, \sigma^2) \in \mathbb{R}^{d+1} \times (0, \infty)$

- ▶ Tavoitteena selvittää parametrin θ arvo ehdolla havaittu aineisto \mathbf{y} .

- ▶ Tavoitteena selvittää parametrin θ arvo ehdolla havaittu aineisto \mathbf{y} .
- ▶ Piste-estimointi: esimerkiksi kruunan todennäköisyyttä voidaan estimoida kruunien havaitulla osuudella $\hat{\theta} = \frac{y}{n}$.

- ▶ Tavoitteena selvittää parametrin θ arvo ehdolla havaittu aineisto \mathbf{y} .
- ▶ Piste-estimointi: esimerkiksi kruunan todennäköisyyttä voidaan estimoida kruunien havaitulla osuudella $\hat{\theta} = \frac{y}{n}$.
 - ▶ Tämä on binomijakauman parameterin **suurimman uskottavuuden estimaatti**, eli **SU**-estimaatti (maximum likelihood estimate, a.k.a. MLE estimate), joka on siis uskottavuusfunktion suurin arvo, eli uskottavuusfunktion moodi:

$$\hat{\theta}(\mathbf{y}) = \operatorname{argmax}_{\theta} p(\mathbf{y}|\theta).$$

- ▶ Tilastollisen päättelyn tavoitteena on parametrin todennäköisimpien arvojen estimoinnin lisäksi myös kvantifioida näihin estimaatteihin liittyvää epävarmuutta.

- ▶ Tilastollisen päättelyn tavoitteena on parametrin todennäköisimpien arvojen estimoinnin lisäksi myös kvantifioida näihin estimaatteihin liittyvää epävarmuutta.
- ▶ → Kaksi tilastollisen päättelyn teoriaa:

- ▶ Tilastollisen päättelyn tavoitteena on parametrin todennäköisimpien arvojen estimoinnin lisäksi myös kvantifioida näihin estimaatteihin liittyvää epävarmuutta.
- ▶ → Kaksi tilastollisen päättelyn teoriaa:
 - ▶ Frekventistinen eli klassinen tilastollinen päättely

- ▶ Tilastollisen päättelyn tavoitteena on parametrin todennäköisimpien arvojen estimoinnin lisäksi myös kvantifioida näihin estimaatteihin liittyvää epävarmuutta.
- ▶ → Kaksi tilastollisen päättelyn teoriaa:
 - ▶ Frekventistinen eli klassinen tilastollinen päättely
 - ▶ **Bayes-päättely**

- ▶ Tilastollisen päättelyn tavoitteena on parametrin todennäköisimpien arvojen estimoinnin lisäksi myös kvantifioida näihin estimaatteihin liittyvää epävarmuutta.
- ▶ → Kaksi tilastollisen päättelyn teoriaa:
 - ▶ Frekventistinen eli klassinen tilastollinen päättely
 - ▶ **Bayes-päättely**
- ▶ Mallinnetaanko parametria satunnaismuuttujana (Bayes-päättely), vai kiinteänä, mutta tuntemattomana vakiona (frekventistinen teoria)?

- Mallin parametri θ ajatellaan satunnaismuuttujan Θ realisaationa.

- Mallin parametri θ ajatellaan satunnaismuuttujan Θ realisaationa.
 - ▶ Kuten aineiston yhteydessä, myös parametria merkitään jatkossa pienellä (yleensä kreikkalaisella) kirjaimella riippumatta siitä tarkoitetaanko satunnaismuuttujaa, vai jotain sen tiettyä arvoa, ellei sekaannuksen vaaraa ole.

- ▶ Jos parametri mallinnetaan satunnaismuuttujana, sen pitää noudattaa jotain todennäköisyysjakaumaa.

- ▶ Jos parametri mallinnetaan satunnaismuuttujana, sen pitää noudattaa jotain todennäköisyysjakaumaa.
- ▶ Mallin parametrin jakaumaa $p(\theta)$ **ennen** aineiston havaitsemista kutsutaan priorijakaumaksi.

- Esimerkiksi kruunan todennäköisyyden θ priorijakaumaksi voidaan valita tasajakauma $U(0, 1)$.

- Esimerkiksi kruunan todennäköisyyden θ priorijakaumaksi voidaan valita tasajakauma $U(0, 1)$.
 - ▶ Tämän priorijakauman mukaan kaikki parametrin arvot välillä $(0, 1)$ ovat yhtä todennäköisiä.

- ▶ Välin $(0, 1)$ tasajakauma on erikoistapaus **beta-jakaumasta**, nimittäin beta-jakauma $\text{Beta}(1, 1)$.

- ▶ Välin $(0, 1)$ tasajakauma on erikoistapaus **beta-jakaumasta**, nimittäin beta-jakauma $\text{Beta}(1, 1)$.
- ▶ Beta-jakauma on välillä $(0, 1)$ määritelty todennäköisyysjakauma, jonka tiheysfunktio on

$$p(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1},$$

missä normalisointivakio $B(\alpha, \beta)$ on ns. Eulerin beta-funktio:

$$B(\alpha, \beta) = \int_0^1 \theta^{\alpha-1} (1 - \theta)^{\beta-1} d\theta.$$

- ▶ Beta-jakautuneen satunnaismuuttujan $\theta \sim \text{Beta}(\alpha, \beta)$ odotusarvo on $E\theta = \frac{\alpha}{\alpha+\beta}$

- ▶ Beta-jakautuneen satunnaismuuttujan $\theta \sim \text{Beta}(\alpha, \beta)$ odotusarvo on $E\theta = \frac{\alpha}{\alpha+\beta}$
- ▶ Jos ennakkokäsitysten mukaan on todennäköisempää että kruunan todennäköisyys on lähempänä puolta kuin nollaa tai yhtä, voidaan valita prioriksi esimerkiksi $\text{Beta}(5, 5)$.

- ▶ Beta-jakautuneen satunnaismuuttujan $\theta \sim \text{Beta}(\alpha, \beta)$ odotusarvo on $E\theta = \frac{\alpha}{\alpha+\beta}$
- ▶ Jos ennakkokäsitysten mukaan on todennäköisempää että kruunan todennäköisyys on lähempänä puolta kuin nollaa tai yhtä, voidaan valita prioriksi esimerkiksi $\text{Beta}(5, 5)$.
 - ▶ Odotusarvo on edelleen $E\theta = \frac{5}{5+5} = \frac{1}{2}$, mutta jakauma keskittyneempi arvoihin lähellä puolta.

- ▶ Beta-jakautuneen satunnaismuuttujan $\theta \sim \text{Beta}(\alpha, \beta)$ odotusarvo on $E\theta = \frac{\alpha}{\alpha+\beta}$
- ▶ Jos ennakkokäsitysten mukaan on todennäköisempää että kruunan todennäköisyys on lähempänä puolta kuin nollaa tai yhtä, voidaan valita prioriksi esimerkiksi $\text{Beta}(5, 5)$.
 - ▶ Odotusarvo on edelleen $E\theta = \frac{5}{5+5} = \frac{1}{2}$, mutta jakauma keskittyneempi arvoihin lähellä puolta.
 - ▶ Priorijakauman parametreja, beta-priorin tapauksessa parametreja α ja β kutsutaan **hyperparametreiksi**.

- Bayes-päätelyn **keskeinen idea** on arviomme parametrin todennäköisistä arvoista ennen havaintojen tekemistä päivittäinen arvioksi aineiston havaitsemisen **jälkeen**.

- ▶ Bayes-päätelyn **keskeinen idea** on arviomme parametrin todennäköisistä arvoista ennen havaintojen tekemistä päivittäinen arvioksi aineiston havaitsemisen **jälkeen**.
- ▶ Parametrin jakaumaa $p(\theta|\mathbf{y})$ ehdolla havaittu aineisto \mathbf{y} kutsutaan parametrin **posteriorijakaumaksi**.

- ▶ Bayes-päätelyn **keskeinen idea** on arviomme parametrin todennäköisistä arvoista ennen havaintojen tekemistä päivittäinen arvioksi aineiston havaitsemisen **jälkeen**.
- ▶ Parametrin jakaumaa $p(\theta|\mathbf{y})$ ehdolla havaittu aineisto \mathbf{y} kutsutaan parametrin **posteriorijakaumaksi**.
 - ▶ Posteriorijakauma siis kuvaa arviotamme parametrin arvojen todennäköisyyksistä aineiston havaitsemisen jälkeen.

- Priorijakauman päivittäminen posteriorijakaumaksi tapahtuu **Bayesin kaavan** avulla:

$$p(\theta|\mathbf{y}) = \frac{p(\theta)p(\mathbf{y}|\theta)}{p(\mathbf{y})}.$$

- Priorijakauman päivittäminen posteriorijakaumaksi tapahtuu **Bayesin kaavan** avulla:

$$p(\theta|\mathbf{y}) = \frac{p(\theta)p(\mathbf{y}|\theta)}{p(\mathbf{y})}.$$

- Periaattellisella tasolla tämä on puolet Bayes-päätelyn keskeisistä kaavoista...

- Priorijakauman päivittäminen posteriorijakaumaksi tapahtuu **Bayesin kaavan** avulla:

$$p(\theta|\mathbf{y}) = \frac{p(\theta)p(\mathbf{y}|\theta)}{p(\mathbf{y})}.$$

- Periaattellisella tasolla tämä on puolet Bayes-päätelyn keskeisistä kaavoista...
- Ja tätäkin voi vielä hieman yksinkertaistaa: posteriorijakauma on parametrin θ funktio, joten aineiston reumatodennäköisyys $p(\mathbf{y})$ on vakio (parametrin suhteen).

- ▶ Priorijakauman päivittäminen posteriorijakaumaksi tapahtuu **Bayesin kaavan** avulla:

$$p(\theta|\mathbf{y}) = \frac{p(\theta)p(\mathbf{y}|\theta)}{p(\mathbf{y})}.$$

- ▶ Periaattellisella tasolla tämä on puolet Bayes-päätelyn keskeisistä kaavoista...
- ▶ Ja tätäkin voi vielä hieman yksinkertaistaa: posteriorijakauma on parametrin θ funktio, joten aineiston reumatodennäköisyys $p(\mathbf{y})$ on vakio (parametrin suhteen).
 - ▶ Usein Bayesin kaavasta käytetään muotoa, jossa posteriori kirjoitetaan verrannollisena otantajakauman ja priorin tuloon:

$$p(\theta|\mathbf{y}) \propto p(\theta)p(\mathbf{y}|\theta).$$

- ▶ Priorijakauman päivittäminen posteriorijakaumaksi tapahtuu **Bayesin kaavan** avulla:

$$p(\theta|\mathbf{y}) = \frac{p(\theta)p(\mathbf{y}|\theta)}{p(\mathbf{y})}.$$

- ▶ Periaattellisella tasolla tämä on puolet Bayes-päätelyn keskeisistä kaavoista...
- ▶ Ja tätäkin voi vielä hieman yksinkertaistaa: posteriorijakauma on parametrin θ funktio, joten aineiston reumatodennäköisyys $p(\mathbf{y})$ on vakio (parametrin suhteen).
 - ▶ Usein Bayesin kaavasta käytetään muotoa, jossa posteriori kirjoitetaan verrannollisena otantajakauman ja priorin tuloon:

$$p(\theta|\mathbf{y}) \propto p(\theta)p(\mathbf{y}|\theta).$$

- ▶ Verrannollisuussymboli $f(x) \propto g(x)$ tarkoittaa, että on olemassa vakio $c \in \mathbb{R}$ s.e. $f(x) = cg(x)$ kaikille x .

- Bayesin kaavan nimittäjää, eli aineiston reumatodennäköisyyttä $p(\mathbf{y})$ kutsutaan **reunauskottavuudeksi** (marginal likelihood).

- Bayesin kaavan nimittäjää, eli aineiston reumatodennäköisyyttä $p(\mathbf{y})$ kutsutaan **reunauskottavuudeksi** (marginal likelihood).
- Jos parametri θ on diskreetti, reunauskottavuus saadaan laskettua kokonaistodennäköisyyden kaavasta summaamalla kaikkien mahdollisten parametrin arvojen yli (vrt. ensimmäinen esimerkki Bayesin kaavasta):

$$p(\mathbf{y}) = \sum_{\theta \in \Omega} p(\theta)p(\mathbf{y}|\theta).$$

- Bayesin kaavan nimittäjää, eli aineiston reunatodennäköisyyttä $p(\mathbf{y})$ kutsutaan **reunauskottavuudeksi** (marginal likelihood).
- Jos parametri θ on diskreetti, reunauskottavuus saadaan laskettua kokonaistodennäköisyyden kaavasta summaamalla kaikkien mahdollisten parametrin arvojen yli (vrt. ensimmäinen esimerkki Bayesin kaavasta):

$$p(\mathbf{y}) = \sum_{\theta \in \Omega} p(\theta) p(\mathbf{y} | \theta).$$

- Jos (ja kun...) parametrilla θ on jatkuva jakauma, joudutaan integroimaan yli parametriavaruuden:

$$p(\mathbf{y}) = \int_{\Omega} p(\theta) p(\mathbf{y} | \theta) d\theta.$$

- ▶ Johdetaan posteriorijakauma mallille, jossa otantajakauma on binomijakauma, ja priorijakauma parametrille θ on betajakauma:

$$y|\theta \sim \text{Bin}(n, \theta)$$
$$\theta \sim \text{Beta}(\alpha, \beta).$$

- ▶ Johdetaan posteriorijakauma mallille, jossa otantajakauma on binomijakauma, ja priorijakauma parametrille θ on betajakauma:

$$y|\theta \sim \text{Bin}(n, \theta)$$
$$\theta \sim \text{Beta}(\alpha, \beta).$$

- ▶ Priorijakauman parametrit voivat olla mitä tahansa vakioita $\alpha, \beta > 0$.

- ▶ Johdetaan posteriorijakauma mallille, jossa otantajakauma on binomijakauma, ja priorijakauma parametrille θ on betajakauma:

$$y|\theta \sim \text{Bin}(n, \theta)$$
$$\theta \sim \text{Beta}(\alpha, \beta).$$

- ▶ Priorijakauman parametrit voivat olla mitä tahansa vakioita $\alpha, \beta > 0$.
 - ▶ Esimerkiksi jos $\alpha = \beta = 1$, priori on tasajakauma

$$\text{Beta}(1, 1) \stackrel{d}{=} U(0, 1).$$

- Sovelletaan verrannollisuusversiota Bayesin kaavasta:

$$\begin{aligned} p(\theta|y) &\propto p(\theta)p(y|\theta) \\ &= \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1} \cdot \binom{n}{y} \theta^y (1-\theta)^{n-y} \\ &\propto \theta^{y+\alpha-1} (1-\theta)^{n-y+\beta-1} \end{aligned}$$

- Sovelletaan verrannollisuusversiota Bayesin kaavasta:

$$\begin{aligned} p(\theta|y) &\propto p(\theta)p(y|\theta) \\ &= \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1} \cdot \binom{n}{y} \theta^y (1-\theta)^{n-y} \\ &\propto \theta^{y+\alpha-1} (1-\theta)^{n-y+\beta-1} \end{aligned}$$

- Viimeiselle riville siirryttäessä poistettiin parametrasta riippumattomat vakiotermit, ja yhdistettiin θ :n ja $(1-\theta)$:n eksponentit.

- ▶ Sovelletaan verrannollisuusversiota Bayesin kaavasta:

$$\begin{aligned} p(\theta|y) &\propto p(\theta)p(y|\theta) \\ &= \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1} \cdot \binom{n}{y} \theta^y (1-\theta)^{n-y} \\ &\propto \theta^{y+\alpha-1} (1-\theta)^{n-y+\beta-1} \end{aligned}$$

- ▶ Viimeiselle riville siirryttäessä poistettiin parametrasta riippumattomat vakiotermiit, ja yhdistettiin θ :n ja $(1-\theta)$:n eksponentit.
- ▶ Tämä voidaan tunnistaa beta-jakauman $\text{Beta}(y + \alpha, n - y + \beta)$ tiheysfunktion ytimeksi (eli normalisoimattomaksi tiheysfunktiksi)

- Posteriorijakaumaksi saatiin johdettua

$$\theta|y \sim \text{Beta}(y + \alpha, n - y + \beta).$$

- Posteriorijakaumaksi saatiin johdettua

$$\theta|y \sim \text{Beta}(y + \alpha, n - y + \beta).$$

- Jos priori on tasajakauma $U(0, 1)$, niin posteriorijakauma on

$$\theta|y \sim \text{Beta}(y + 1, n - y + 1).$$

- ▶ Päättelyprosessi tulos on koko posteriorijakauma.

- ▶ Päättelyprosessi tulos on koko posteriorijakauma.
- ▶ Monesti posteriorijakauma halutaan kuitenkin tiivistää yhteen piste-estimaattiin.

- ▶ Päättelyprosessi tulos on koko posteriorijakauma.
- ▶ Monesti posteriorijakauma halutaan kuitenkin tiivistää yhteen piste-estimaattiin.
- ▶ Voidaan käyttää posteriorijakauman moodia, mediaania, tai odotusarvoa.

- ▶ Päättelyprosessi tulos on koko posteriorijakauma.
- ▶ Monesti posteriorijakauma halutaan kuitenkin tiivistää yhteen piste-estimaattiin.
- ▶ Voidaan käyttää posteriorijakauman moodia, mediaania, tai odotusarvoa.
- ▶ Bayes-päättelyssä piste-estimaattina käytetään yleensä posteriorijakauman odotusarvoa

$$E(\theta|Y = y)$$

- ▶ Päättelyprosessi tulos on koko posteriorijakauma.
- ▶ Monesti posteriorijakauma halutaan kuitenkin tiivistää yhteen piste-estimaattiin.
- ▶ Voidaan käyttää posteriorijakauman moodia, mediaania, tai odotusarvoa.
- ▶ Bayes-päättelyssä piste-estimaattina käytetään yleensä posteriorijakauman odotusarvoa

$$E(\theta|Y = y)$$

- ▶ Voidaan osoittaa, että tämä on keskineliövirheen mielessä optimaalinen piste-estimaatti.

- ▶ Kolikonheittoesimerkissä posteriorijakauman odotusarvo saadaan laskettua helposti beta-jakauman odotusarvona

$$E(\theta|Y = y) = \frac{y + \alpha}{n + \alpha + \beta}.$$

- ▶ Kolikonheittoesimerkissä posteriorijakauman odotusarvo saadaan laskettua helposti beta-jakauman odotusarvona

$$E(\theta|Y = y) = \frac{y + \alpha}{n + \alpha + \beta}.$$

- ▶ Käytettäessä tasajakaumaa $U(0, 1)$ priorina, posteriorijakauman odotusarvo on

$$E(\theta|Y = y) = \frac{y + 1}{n + 2}.$$

- ▶ Kolikonheittoesimerkissä posteriorijakauman odotusarvo saadaan laskettua helposti beta-jakauman odotusarvona

$$E(\theta|Y = y) = \frac{y + \alpha}{n + \alpha + \beta}.$$

- ▶ Käytettäessä tasajakaumaa $U(0, 1)$ priorina, posteriorijakauman odotusarvo on

$$E(\theta|Y = y) = \frac{y + 1}{n + 2}.$$

- ▶ Priorijakauman tulkinta pseudo-havaintoina.
 - ▶ Lisätään oikeisiin havaintoihin yhteensä $\alpha + \beta$ pseudo-havaintoa, joista α kruunaa ja β klaavaa.

- ▶ Kolikonheittoesimerkissä posteriorijakauman odotusarvo saadaan laskettua helposti beta-jakauman odotusarvona

$$E(\theta|Y = y) = \frac{y + \alpha}{n + \alpha + \beta}.$$

- ▶ Käytettäessä tasajakaumaa $U(0, 1)$ priorina, posteriorijakauman odotusarvo on

$$E(\theta|Y = y) = \frac{y + 1}{n + 2}.$$

- ▶ Priorijakauman tulkinta pseudo-havaintoina.
 - ▶ Lisätään oikeisiin havaintoihin yhteensä $\alpha + \beta$ pseudo-havaintoa, joista α kruunaa ja β klaavaa.
 - ▶ α ja β eivät välttämättä kokonaislukuja, esim. prior $\text{Beta}(\frac{1}{2}, \frac{1}{2})$ vastaa puolen kruunan ja puolen klaavan lisäämistä aineistoon.

- ▶ Todennäköisyysjakauma parametrien arvojen yli:

$$p(\theta|y) = ?$$

- ▶ Todennäköisyysjakauma parametrien arvojen yli:

$$\cancel{p(\theta|y) = ?}$$

... ei ole hyvin määritelty.

- ▶ Todennäköisyysjakauma parametrien arvojen yli:

$$\cancel{p(\theta|y) = ?}$$

... ei ole hyvin määritelty.

- ▶ Mallin parametriin ei voida liittää todennäköisyysväittämiä, vaan se on kiinteä, mutta tuntematon vakio.

- ▶ Todennäköisyysjakauma parametrien arvojen yli:

$$\cancel{p(\theta|y) = ?}$$

... ei ole hyvin määritelty.

- ▶ Mallin parametriin ei voida liittää todennäköisyysväittämiä, vaan se on kiinteä, mutta tuntematon vakio.
 - ▶ Kiinnitetään parametrin arvo, esim. $H_0 : \theta = 0.5$, ja tarkastellaan otantajakaumaa $p(y|\theta)$.

- ▶ Todennäköisyysjakauma parametrien arvojen yli:

$$\cancel{p(\theta|y) = ?}$$

... ei ole hyvin määritelty.

- ▶ Mallin parametriin ei voida liittää todennäköisyysväittämiä, vaan se on kiinteä, mutta tuntematon vakio.
 - ▶ Kiinnitetään parametrin arvo, esim. $H_0 : \theta = 0.5$, ja tarkastellaan otantajakaumaa $p(y|\theta)$.
 - ▶ Mikä on todennäköisyys havaita vähintään yhtä äärimmäinen aineisto kuin havaittu aineisto kiinnitetyllä parameterin arvolla?

- ▶ Todennäköisyysjakauma parametrien arvojen yli:

$$\cancel{p(\theta|y) = ?}$$

... ei ole hyvin määritelty.

- ▶ Mallin parametriin ei voida liittää todennäköisyysväittämiä, vaan se on kiinteä, mutta tuntematon vakio.
 - ▶ Kiinnitetään parametrin arvo, esim. $H_0 : \theta = 0.5$, ja tarkastellaan otantajakaumaa $p(y|\theta)$.
 - ▶ Mikä on todennäköisyys havaita vähintään yhtä äärimmäinen aineisto kuin havaittu aineisto kiinnitetyllä parameterin arvolla?
 - ▶ Esimerkiksi mikä on todennäköisyys, että 10 heitolla saadaan 2 tai alle 2 kruunaa (tai vastaavasti klaavaa), jos kruunan todennäköisyys on 0.5?


- ▶ p -arvo: todennäköisyys, että 10 heitolla saadaan 2 tai alle 2 kruunaa (tai vastaavasti klaavaa), jos kruunan todennäköisyys on 0.5:

$$p = P(Y \leq 2 \cup Y \geq 8 | \theta = 0.5) \approx 0.109$$

- ▶ p -arvo: todennäköisyys, että 10 heitolla saadaan 2 tai alle 2 kruunaa (tai vastaavasti klaavaa), jos kruunan todennäköisyys on 0.5:

$$p = P(Y \leq 2 \cup Y \geq 8 | \theta = 0.5) \approx 0.109$$


- ▶ Verrataan p -arvoa etukäteen määriteltyyn merkitsevyystasoon (esim. $\alpha = 0.05$): tässä tapauksessa $p = 0.109 > 0.05$, joten nollahypoteesia ei voida hylätä.



- ▶ p -arvo: todennäköisyys, että 10 heitolla saadaan 2 tai alle 2 kruunaa (tai vastaavasti klaavaa), jos kruunan todennäköisyys on 0.5:

$$p = P(Y \leq 2 \mid Y \sim \text{Bin}(10, 0.5)) \approx 0.109$$

- ▶ Verrataan p -arvoa etukäteen määriteltyyn merkitsevyystasoon (esim. $\alpha = 0.05$): tässä tapauksessa $p = 0.109 > 0.05$, joten nollahypoteesia ei voida hylätä.



- ▶ Esihistoria 1700-1900: Bayes ja Laplace
- ▶ Modernin tilastotieteen kehitys 1900-1930
- ▶ Frekventismin valtakausi 1930-1960
- ▶ Bayes-päättelyn uusi tuleminen 1960-2000
- ▶ Nykyaika 2000 -

- ▶ Englantilainen presbyteeripappi ja amatöörimatemaatikko.
- ▶ Ei julkaissut mitään todennäköisyyteen liittyvää elinaikanaan.
- ▶ Bayesin ystävä Richard Price editoi hänen jäämistöstään löytyneen käsikirjoituksen, joka julkaistiin 1763 nimellä *An essay towards solving a problem in the doctrine of chances*.
 - ▶ Sisältää erikoistapauksen **Bayesin kaavasta**
 - ▶ Fyysinen analogia: parametrin sijainnin parametriavaruudessa kuvaaminen pallon sijaintina biljardipöydällä.



- ▶ Ranskalainen matemaatikko ja fyysikko, "Ranskan Newton"
- ▶ Merkittäviä läpimurtoja matemaattisessa fysiikassa, astronomiassa ja erityisesti **todennäköisyyslaskennassa** ja **tilastotieteessä**:
 - ▶ todennäköisyysgeneroiva ja karakteristinen funktio
 - ▶ pienimmän neliösumman menetelmä
 - ▶ keskeinen raja-arvolause
 - ▶ **Bayesin kaava** yleisessä muodossa



- 1745 - 1770 Pariisissa syntyi $n = 493472$ lasta, joista $y = 241945$ oli tyttöjä (ja vastaavasti $n - y = 251527$ poikia).

- ▶ 1745 - 1770 Pariisissa syntyi $n = 493472$ lasta, joista $y = 241945$ oli tyttöjä (ja vastaavasti $n - y = 251527$ poikia).
- ▶ Voidaanko tämän aineiston perusteella päätellä, syntyykö poikia enemmän kuin tyttöjä?

- 1745 - 1770 Pariisissa syntyi $n = 493472$ lasta, joista $y = 241945$ oli tyttöjä (ja vastaavasti $n - y = 251527$ poikia).
- Voidaanko tämän aineiston perusteella päätellä, syntyykö poikia enemmän kuin tyttöjä?
- Sama malli kuin kolikko-esimerkissä! Laskettava posteriorijakauman perusteella todennäköisyys

$$p(\theta > 0.5|y) = ?$$

- Posteriorijakaumaksi saadaan

$$\text{Beta}(241945 + 1, 251527 + 1) \stackrel{d}{=} \text{Beta}(241946, 251528)$$

- Posteriorijakaumaksi saadaan

$$\text{Beta}(241945 + 1, 251527 + 1) \stackrel{d}{=} \text{Beta}(241946, 251528)$$

- Posteriorijakauman odotusarvo on

$$E[\theta | Y = y] = \frac{241946}{241946 + 251527} \approx 0.49$$

- Posteriorijakaumaksi saadaan

$$\text{Beta}(241945 + 1, 251527 + 1) \stackrel{d}{=} \text{Beta}(241946, 251528)$$

- Posteriorijakauman odotusarvo on

$$E[\theta | Y = y] = \frac{241946}{241946 + 251527} \approx 0.49$$

- Posteriorijakaumasta saadaan laskettua todennäköisyys että tytön todennäköisyys on suurempaa kuin puoli:

$$p(\theta > 0.5) \approx 1.15 \cdot 10^{-42}$$

- Posteriorijakaumaksi saadaan

$$\text{Beta}(241945 + 1, 251527 + 1) \stackrel{d}{=} \text{Beta}(241946, 251528)$$

- Posteriorijakauman odotusarvo on

$$E[\theta | Y = y] = \frac{241946}{241946 + 251527} \approx 0.49$$

- Posteriorijakaumasta saadaan laskettua todennäköisyys että tytön todennäköisyys on suurempaa kuin puoli:

$$p(\theta > 0.5) \approx 1.15 \cdot 10^{-42}$$


- Laplace oli tämän perusteella "moraalisesti varma", että poikia syntyy enemmän kuin tyttöjä.

- ▶ 1900-luvun alussa Karl Pearson, William Gosset (a.k.a. "student"), Jerzy Neyman ja **Ronald Fisher** kehittivät formaalia tilastollisen päättelyn teoriaa.
- ▶ Fisher: *Statistical methods for research workers*, 1925: Ensimmäinen soveltajille suunnattu tilastotieteen metodiopas.
- ▶ Fisherin teoria tunnetaan nykyään **frekventistisenä** tai **klassisena** tilastotieteenä.




Sir Ronald Fisher

- ▶ Samaan aikaan brittiläinen matemaatikko ja geofyysikko Harold Jeffreys kehitti 1930-luvulla Bayesiläistä vaihtoehtoa Fisherin p -arvoille ja merkitsevyystesteille: *Bayes-faktorit*




Harold Jeffreys (1891-1989)

- ▶ Samaan aikaan brittiläinen matemaatikko ja geofyysikko Harold Jeffreys kehitti 1930-luvulla Bayesiläistä vaihtoehtoa Fisherin p -arvoille ja merkitsevyyystesteille: *Bayes-faktorit*
- ▶ "Ainoa Bayesiläinen" 30-luvulla



Harold Jeffreys (1891-1989)

- ▶ Samaan aikaan brittiläinen matemaatikko ja geofyysikko Harold Jeffreys kehitti 1930-luvulla Bayesiläistä vaihtoehtoa Fisherin p -arvoille ja merkitsevyyystesteille: *Bayes-faktorit*
- ▶ "Ainoa Bayesiläinen" 30-luvulla
- ▶ *Theory of probability*, 1939: Pitkän aikaa ainoa teos, jossa selitetään kuinka soveltaa Bayesiläisiä menetelmiä.



- Fisher vastusti hyvin voimakkaasti Bayesiläistä tilastotiedettä



- Fisher vastusti hyvin voimakkaasti Bayesiläistä tilastotiedettä
 - ▶ *"The theory of inverse probability is founded upon an error, and must be wholly rejected"*.



- Fisher vastusti hyvin voimakkaasti Bayesiläistä tilastotiedettä
 - ▶ *"The theory of inverse probability is founded upon an error, and must be wholly rejected"*.
 - ▶ Ihaili Bayesiä ongelman muotoilusta, sen ratkaisemisesta, mutta ennen kaikkea siitä, että tämä ei ikinä julkaissut ratkaisuaan...



- Fisher vastusti hyvin voimakkaasti Bayesiläistä tilastotiedettä
 - ▶ *"The theory of inverse probability is founded upon an error, and must be wholly rejected"*.
 - ▶ Ihaili Bayesiä ongelman muotoilusta, sen ratkaisemisesta, mutta ennen kaikkea siitä, että tämä ei ikinä julkaissut ratkaisuaan...
- Kiivasta väittelyä Jeffreys'n kanssa tieteellisissä julkaisuissa ja konferensseissa.




- Frekventistisestä tilastotieteestä tuli valtavirtaa, ja Bayesiläisten menetelmien kehittäminen ja käyttäminen lakkasi käytännössä kokonaan useiksi vuosikymmeniksi.

- Frekventistisestä tilastotieteestä tuli valtavirtaa, ja Bayesiläisten menetelmien kehittäminen ja käyttäminen lakkasi käytännössä kokonaan useiksi vuosikymmeniksi.
 - ▶ Helpompi soveltaa, selkeät säännöt ja ei tarvetta priorijakaumalle.

- Frekventistisistä tilastotieteistä tuli valtavirtaa, ja Bayesiläisten menetelmien kehittäminen ja käyttäminen lakkasi käytännössä kokonaan useiksi vuosikymmeniksi.
 - ▶ Helpompi soveltaa, selkeät säännöt ja ei tarvetta priorijakaumalle.
 - ▶ "Objektiivisempi" lähestymistapa, ei subjektiivisuutta, joka liittyy priorin valintaan.

- Frekventistisistä tilastotieteistä tuli valtavirtaa, ja Bayesiläisten menetelmien kehittäminen ja käyttäminen lakkasi käytännössä kokonaan useiksi vuosikymmeniksi.
 - ▶ Helpompi soveltaa, selkeät säännöt ja ei tarvetta priorijakaumalle.
 - ▶ "Objektiivisempi" lähestymistapa, ei subjektiivisuutta, joka liittyy priorin valintaan.
 - ▶ **Laskennallisesti** kevyempää: vain kaikkein yksinkertaisimpien Bayesiläisten mallien sovittaminen mahdollista ennen tietokoneita.

- Teorian kehitys: Dennis Lindley (1923-2013) ja Jimmie Savage (1917-1971) kehittivät aksiomaattista perustaa tilastotieteelle.




Dennis Lindley



Jimmie Savage

- Teorian kehitys: Dennis Lindley (1923-2013) ja Jimmie Savage (1917-1971) kehittivät aksiomaattista perustaa tilastotieteelle.
 - Johtaa Bayesiläiseen teoriaan 'lähes vahingossa'*




Dennis Lindley



Jimmie Savage

- Teorian kehitys: Dennis Lindley (1923-2013) ja Jimmie Savage (1917-1971) kehittivät aksiomaattista perustaa tilastotieteelle.
 - Johtaa Bayesiläiseen teoriaan 'lähes vahingossa'*
- Tietokoneiden ja simulaatiomenetelmien, erityisesti Markov chain Monte Carlo (MCMC), kehitys mahdollisti monimutkaisempien mallien sovittamisen.




Dennis Lindley



Jimmie Savage

- Teorian kehitys: Dennis Lindley (1923-2013) ja Jimmie Savage (1917-1971) kehittivät aksiomaattista perustaa tilastotieteelle.
 - Johtaa Bayesiläiseen teoriaan 'lähes vahingossa'*
- Tietokoneiden ja simulaatiomenetelmien, erityisesti Markov chain Monte Carlo (MCMC), kehitys mahdollisti monimutkaisempien mallien sovittamisen.
- Hierarkkisten mallien kehittäminen: hyviä käytännön tuloksia.



Dennis Lindley



Jimmie Savage

- Frekventistiset menetelmät edelleen valtavirtaa monilla sovellusaloilla, kuten lääketieteessä.

- ▶ Frekventistiset menetelmät edelleen valtavirtaa monilla sovellusaloilla, kuten lääketieteessä.
 - ▶ Tarvetta selkeille säännöille: esim. lääkkeiden toimivuuden testauksessa.

- ▶ Frekventistiset menetelmät edelleen valtavirtaa monilla sovellusaloilla, kuten lääketieteessä.
 - ▶ Tarvetta selkeille säännöille: esim. lääkkeiden toimivuuden testauksessa.
 - ▶ Pitkät perinteet.

- Frekventistiset menetelmät edelleen valtavirtaa monilla sovellusaloilla, kuten lääketieteessä.
 - ▶ Tarvetta selkeille säännöille: esim. lääkkeiden toimivuuden testauksessa.
 - ▶ Pitkät perinteet.
- Bayesiläiset menetelmät valtaamassa alaa tilastotieteen teoriassa ja monilla sovellusaloilla, kuten biologiassa.

- Frekventistiset menetelmät edelleen valtavirtaa monilla sovellusaloilla, kuten lääketieteessä.
 - ▶ Tarvetta selkeille säännöille: esim. lääkkeiden toimivuuden testauksessa.
 - ▶ Pitkät perinteet.
- Bayesiläiset menetelmät valtaamassa alaa tilastotieteen teoriassa ja monilla sovellusaloilla, kuten biologiassa.
 - ▶ Koneoppimisen ja tekoälyn tutkimuksessa käytössä Bayesiläiset menetelmät valtavirtaa (silloin kun ei tehdä pelkkää piste-estimointia).

- Frekventistiset menetelmät edelleen valtavirtaa monilla sovellusaloilla, kuten lääketieteessä.
 - ▶ Tarvetta selkeille säännöille: esim. lääkkeiden toimivuuden testauksessa.
 - ▶ Pitkät perinteet.
- Bayesiläiset menetelmät valtaamassa alaa tilastotieteen teoriassa ja monilla sovellusaloilla, kuten biologiassa.
 - ▶ Koneoppimisen ja tekoälyn tutkimuksessa käytössä Bayesiläiset menetelmät valtavirtaa (silloin kun ei tehdä pelkkää piste-estimointia).
- Probabilistinen ohjelmointi (probabilistic programming)

- Frekventistiset menetelmät edelleen valtavirtaa monilla sovellusaloilla, kuten lääketieteessä.
 - ▶ Tarvetta selkeille säännöille: esim. lääkkeiden toimivuuden testauksessa.
 - ▶ Pitkät perinteet.
- Bayesiläiset menetelmät valtaamassa alaa tilastotieteen teoriassa ja monilla sovellusaloilla, kuten biologiassa.
 - ▶ Koneoppimisen ja tekoälyn tutkimuksessa käytössä Bayesiläiset menetelmät valtavirtaa (silloin kun ei tehdä pelkkää piste-estimointia).
- Probabilistinen ohjelmointi (probabilistic programming)
 - ▶ Mahdollistaa Bayes-mallien käyttämisen *lähes* out-of-the-box.

- Nykyään ei enää juurikaan vastakkainasettelua frekventistisen ja Bayes-päättelyn välillä.

- ▶ Nykyään ei enää juurikaan vastakkainasettelua frekventistisen ja Bayes-päätelyn välillä.
- ▶ Vaikka Bayes-päätelyssä parametria mallinnetaan satunnaismuuttujana, voidaan kuitenkin puhua myös parametrin todellisesta arvosta.

- ▶ Nykyään ei enää juurikaan vastakkainasettelua frekventistisen ja Bayes-päätelyn välillä.
- ▶ Vaikka Bayes-päätelyssä parametria mallinnetaan satunnaismuuttujana, voidaan kuitenkin puhua myös parametrin todellisesta arvosta.
 - ▶ Voidaan puhua estimaattorien asymptoottisista ominaisuuksista, kuten tarkentuvuus (consistency) ja konvergenssinopeus (convergence rate).

Motivaatio: miksi Bayes?

- ▶ Analyysin tulokset helpompia tulkita (oikein!).



- Analyysin tulokset helpompia tulkita (oikein!).
 - ▶ Voidaan antaa suoraan todennäköisyyksiä parametrin arvoille.



- Analyysin tulokset helpompia tulkita (oikein!).
 - ▶ Voidaan antaa suoraan todennäköisyyksiä parametrin arvoille.
 - ▶ Bayesiläinen uskottavuusväli: väli, jolle parametrin arvo kuuluu 95% todennäköisyydellä.



- ▶ Analyysin tulokset helpompia tulkita (oikein!).
 - ▶ Voidaan antaa suoraan todennäköisyyksiä parametrin arvoille.
 - ▶ Bayesiläinen uskottavuusväli: väli, jolle parametrin arvo kuuluu 95% todennäköisyydellä.
- ▶ Välineet myös *ennustamiseen*, ei pelkästään selittämiseen.



- Analyysin tulokset helpompia tulkita (oikein!).
 - ▶ Voidaan antaa suoraan todennäköisyyksiä parametrin arvoille.
 - ▶ Bayesiläinen uskottavuusväli: väli, jolle parametrin arvo kuuluu 95% todennäköisyydellä.
- Välineet myös *ennustamiseen*, ei pelkästään selittämiseen.
 - ▶ Vakuutusala, vedonlyönti, koneoppimis- ja tekoälyjärjestelmät, jne.



- ▶ Analyysin tulokset helpompia tulkita (oikein!).
 - ▶ Voidaan antaa suoraan todennäköisyyksiä parametrin arvoille.
 - ▶ Bayesiläinen uskottavuusväli: väli, jolle parametrin arvo kuuluu 95% todennäköisyydellä.
- ▶ Välineet myös *ennustamiseen*, ei pelkästään selittämiseen.
 - ▶ Vakuutusala, vedonlyönti, koneoppimis- ja tekoälyjärjestelmät, jne.
- ▶ Kaunis ja yhtenäinen teoria, joka selittää paljon sitä, mitä käytännön sovelluksissa tehdään.



- ▶ Analyysin tulokset helpompia tulkita (oikein!).
 - ▶ Voidaan antaa suoraan todennäköisyyksiä parametrin arvoille.
 - ▶ Bayesiläinen uskottavuusväli: väli, jolle parametrin arvo kuuluu 95% todennäköisyydellä.
- ▶ Välineet myös *ennustamiseen*, ei pelkästään selittämiseen.
 - ▶ Vakuutusala, vedonlyönti, koneoppimis- ja tekoälyjärjestelmät, jne.
- ▶ Kaunis ja yhtenäinen teoria, joka selittää paljon sitä, mitä käytännön sovelluksissa tehdään.
 - ▶ Regularisaatio, smoothing, pseudohavainnot jne. tulkittavissa priorijakaumana.



- ▶ Eikö priorijakauman valinta tee analyysistä subjektiivista?

- ▶ Eikö priorijakauman valinta tee analyysistä subjektiivista?
 - ▶ Myös otantajakauman valinta aina subjektiivinen päätös!

- ▶ Eikö priorijakauman valinta tee analyysistä subjektiivista?
 - ▶ Myös otantajakauman valinta aina subjektiivinen päätös!
 - ▶ Esim. klassinen lineaarinen regressio: hyvin voimakkaita oletuksia, kuten riippuvuuden lineaarisuus, virhetermien normaalijakautuneisuus ja heteroskedastisuus, jne.

- ▶ Eikö priorijakauman valinta tee analyysistä subjektiivista?
 - ▶ Myös otantajakauman valinta aina subjektiivinen päätös!
 - ▶ Esim. klassinen lineaarinen regressio: hyvin voimakkaita oletuksia, kuten riippuvuuden lineaarisuus, virhetermien normaalijakautuneisuus ja heteroskedastisuus, jne.
- ▶ Mallien sovittaminen työlästä: vielä 10 vuotta MCMC-sämpleri uudelle mallille johdettiin ja kirjoitettiin monesti itse

- ▶ Eikö priorijakauman valinta tee analyysistä subjektiivista?
 - ▶ Myös otantajakauman valinta aina subjektiivinen päätös!
 - ▶ Esim. klassinen lineaarinen regressio: hyvin voimakkaita oletuksia, kuten riippuvuuden lineaarisuus, virhetermien normaalijakautuneisuus ja heteroskedastisuus, jne.
- ▶ Mallien sovittaminen työlästä: vielä 10 vuotta MCMC-sämpleri uudelle mallille johdettiin ja kirjoitettiin monesti itse
 - ▶ Vaatii monen viikon työn tilastotieteilijältä.

- ▶ Eikö priorijakauman valinta tee analyysistä subjektiivista?
 - ▶ Myös otantajakauman valinta aina subjektiivinen päätös!
 - ▶ Esim. klassinen lineaarinen regressio: hyvin voimakkaita oletuksia, kuten riippuvuuden lineaarisuus, virhetermien normaalijakautuneisuus ja heteroskedastisuus, jne.
- ▶ Mallien sovittaminen työlästä: vielä 10 vuotta MCMC-sämpleri uudelle mallille johdettiin ja kirjoitettiin monesti itse
 - ▶ Vaatii monen viikon työn tilastotieteilijältä.
 - ▶ Nykyään kuitenkin yleiskäyttöisiä Hamiltonian Monte Carlo (HMC)-sämplereitä ja niiden helppokäyttöisiä implementaatioita, kuten **Stan**, PyMC3 ja Edward (probabilistic programming tools).

- ▶ Eikö priorijakauman valinta tee analyysistä subjektiivista?
 - ▶ Myös otantajakauman valinta aina subjektiivinen päätös!
 - ▶ Esim. klassinen lineaarinen regressio: hyvin voimakkaita oletuksia, kuten riippuvuuden lineaarisuus, virhetermien normaalijakautuneisuus ja heteroskedastisuus, jne.
- ▶ Mallien sovittaminen työlästä: vielä 10 vuotta MCMC-sämpleri uudelle mallille johdettiin ja kirjoitettiin monesti itse
 - ▶ Vaatii monen viikon työn tilastotieteilijältä.
 - ▶ Nykyään kuitenkin yleiskäyttöisiä Hamiltonian Monte Carlo (HMC)-sämplereitä ja niiden helppokäyttöisiä implementaatioita, kuten **Stan**, PyMC3 ja Edward (probabilistic programming tools).
 - ▶ Riittää määritellä pelkästään malli, sovittaminen automaattista.